Машинное обучение

Лекция 1: Введение в Машинное обучение

Дьулустан Никифоров

Кафедра ИТ
Северо-Восточный Федеральный Университет

Весна 2026

Литература к курсу

- Introduction to Machine Learning — курс, преподаваемый андеградам в MIT.
- Хэндбук от Яндекса по машинному обучению.
- Machine Learning Specialization — курс от Andrew Ng.
- `https://slds-lmu.github.io/i2ml/`

Искусственный Интеллект (Artificial Intelligence)

Искусственный Интеллект (Artificial Intelligence) — это комплекс технологий, которые позволяют компьютерам и машинам имитировать человеческое обучение, понимание, решение проблем, принятие решений, творчество и автономность.
В современном ИИ можно выделить такие области:

- Машинное обучение (Machine learning)
- Глубокое обучение (Deep learning)
- Обработка естественного языка (Natural Language Processing)
- Компьютерное зрение (Computer Vision)

Искусственный Интеллект (Artificial Intelligence)

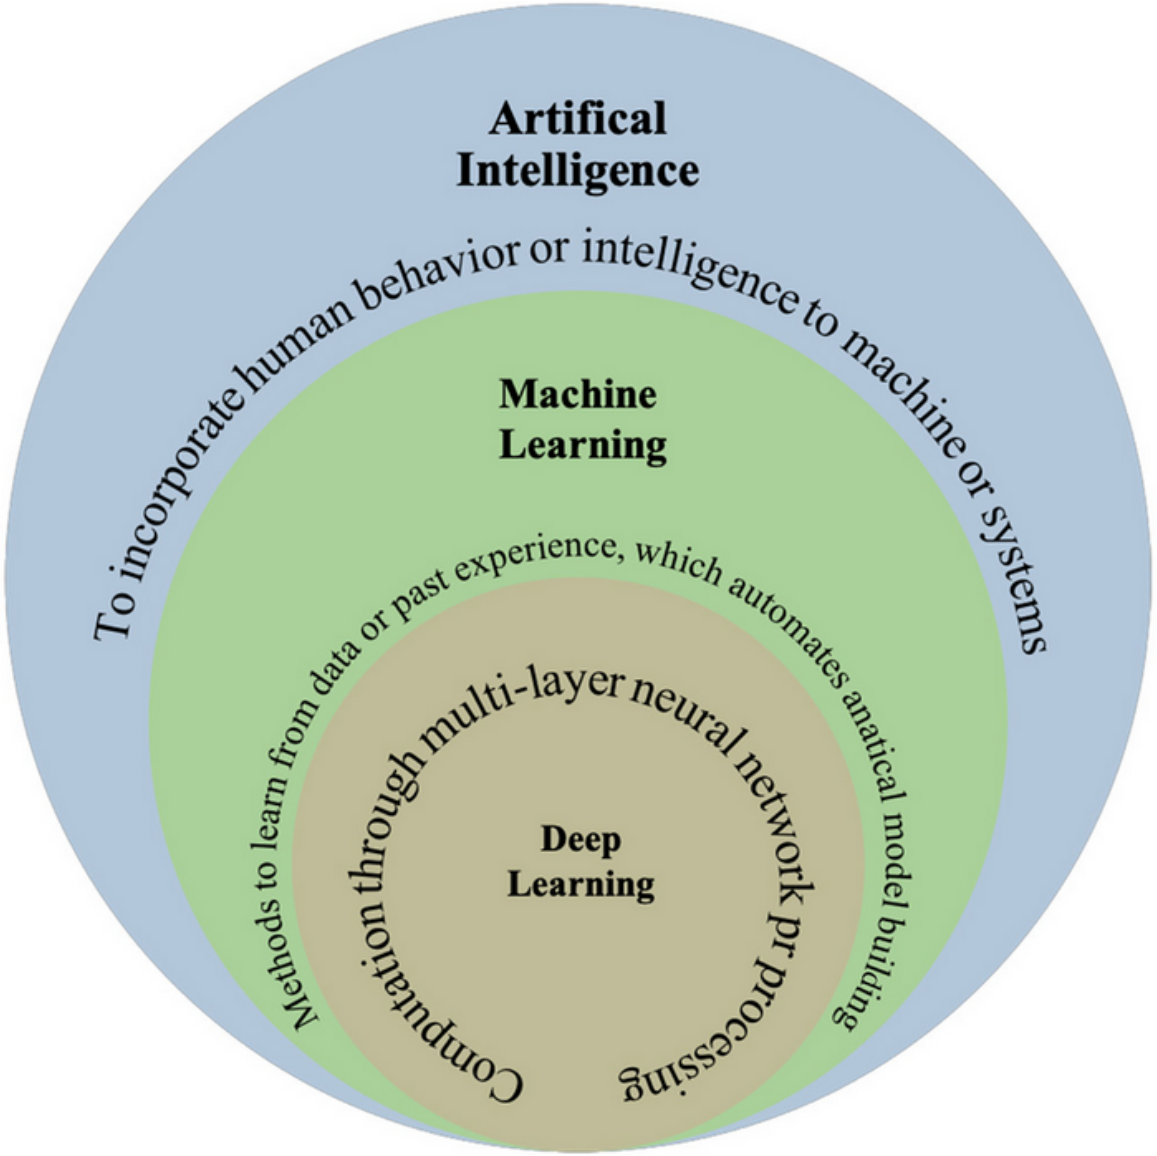

Машинное обучение

Машинное обучение — это часть computer science, которая изучает алгоритмы, автоматически улучшающиеся благодаря опыту.

Цель машинного обучения — делать *предсказания (predictions)* на основе данных.

Конечно, есть и другие большие области науки (статистика, эконометрика, ...), которые делают примерно то же самое и используют похожие методики.

Тогда чем же ML отличается от них?

Машинное обучение

Машинное обучение — это часть computer science, которая изучает алгоритмы, автоматически улучшающиеся благодаря опыту.

Цель машинного обучения — делать *предсказания (predictions)* на основе данных.

Конечно, есть и другие большие области науки (статистика, эконометрика, ...), которые делают примерно то же самое и используют похожие методики.

Тогда чем же ML отличается от них?

- Статистика (и прочие) ставят конечной целью построить хорошие понятные модели, которые дают хорошо интерпретируемые результаты и поддаются анализу.
- ML ставит конечной целью добиться очень хороший предсказаний, и для этого чересчур сложные модели служат чисто как инструмент.

Машинное обучение: Классы задач

В ML выделяют такие классы (виды) постановок задачи:

- **Обучение с учителем (Supervised learning)**. Данные состоят из *объектов* и *ответов* к ним.
- **Обучение без учителя (Unsupervised learning)**. Данные состоят только из *объектов*, ответы не даются.
- **Обучение с подкреплением (Reinforcement learning)**. Тут есть «агент», который взаимодействует с данными.
- **Semi-supervised learning**. Малая часть данных имеет ответы, но остальная часть без ответов.

Мы будем изучать Обучение с учителем — самый большой и самый актуальный из классов.

Обучение с учителем

Данные = Обучающая выборка = Датасет = Training data.

Обучающая выборка — это множество пар

$$\mathcal{D}_n = \{(x^{(1)}, y^{(1)}), \ldots, (x^{(n)}, y^{(n)})\},$$

где $x^{(i)}$ — *объекты*, $y^{(i)}$ — *ответы (таргеты)* к ним.

Задача — на основе обучающей выборки научиться *предсказывать* y по x для новых значений x.

Обозначим $\mathbb{X}$ — множество возможных значений x, $\mathbb{Y}$ — множество всех возможных значений y.

Обучение с учителем: виды задач

$\mathbb{X} = \mathbb{R}^d$

Задачи обучения с учителем разбиваются на классы в зависимости от $\mathbb{Y}$:

- $\mathbb{Y} = \mathbb{R}^k$ — **Регрессия (regression)**.
- $\mathbb{Y} = \{1, ..., K\}$ — **Классификация (classification)**.
  - $\mathbb{Y} = \{1, -1\}$ — **бинарная классификация**.
  - $\mathbb{Y}$ содержит больше двух значений — **многоклассовая классификация**.

Примеры классификации и регрессии

- Детекция спама в имейле.
- Распознавание котов на фотографиях.
- Предсказание цены недвижимости.
- Предсказание погоды.

Какие еще примеры можете назвать?

Математический ликбез

Дальше нужно будет вспомнить линейную алгебру!

n-мерный вектор-столбец — это $c = \begin{bmatrix} c_0 \\ \dots \\ c_{n-1} \end{bmatrix} = \begin{bmatrix} c_0 & \dots & c_{n-1} \end{bmatrix}^T$

m-мерный вектор-строка — это $r = \begin{bmatrix} r_0 & \dots & r_{m-1} \end{bmatrix}$

Вектора одинаковой формы и размера можно прибавлять / вычитать друг к другу.
Вектора можно умножать / делить на скаляр.

Математический ликбез

Вектора можно скалярно умножать (**dot product**).

Класс моделей

Итак, у нас есть

$$\mathcal{D}_n = \{(x^{(1)}, y^{(1)}), \ldots, (x^{(n)}, y^{(n)})\},$$

где $x^{(i)} \in \mathbb{X}$, $y^{(i)} \in \mathbb{Y}$.

Чтобы дальше сделать что-то продуктивное, нам необходимо структуризовать задачу. Для этого придумаем пространство возможных решений к нашей задаче.

$$y = h(x; \theta),$$

где $h \in \mathcal{H}$ — **модель / гипотеза**.
$\mathcal{H}$ — **класс моделей / класс гипотез** (model class / hypothesis class).
Для параметров есть свое пространство:

$$\theta = (\theta_0, \theta_1, ..., \theta_d) \in \Theta,$$

где Θ — пространство параметров (parameter space).

Функция потерь

После выбора $\mathcal{H}$, задача сводится к подбору оптимальных параметров θ.
Чтобы найти оптимальное решение, необходимо уметь измерять их «неоптимальность».

Для этого вводим понятие **функции потерь (loss function)**: $L(g, a)$ — мера «ошибочности» предсказанного ответа g, если настоящий ответ a.

Функция потерь

Примеры популярных функций потерь:

- **0-1 потеря** $L(g, a) = \begin{cases} 1, & \text{если } g \neq a \\ 0, & \text{иначе.} \end{cases}$
- **Квадратичная потеря** $L(g, a) = (g - a)^2$.
- **Линейная потеря** $L(g, a) = |g - a|$.
- **Асимметричная потеря**

$$L(g, a) = \begin{cases} 1, & \text{если } g = 1 \text{ и } a = 0 \\ 10, & \text{если } g = 0 \text{ и } a = 1 \\ 0, & \text{иначе.} \end{cases}$$

Когда может быть полезна эта асимметричная функция потерь?

Функция потерь

Что мы реально хотим: минимальную потерю (лосс) найденного решения на *новых* данных.

Мы этого не можем сделать $\Rightarrow$ но мы можем попробовать минимизировать потери на обучающих данных.

$$\mathcal{E}_n(h) = \frac{1}{n}\sum_{i=1}^{n} L(h(x^{(i)}), y^{(i)}) \text{ — } \textbf{training set error}$$

В целом, мы хотим минимизировать $\mathcal{E}_n(h)$ и надеяться, что это приведет к минимизации потерь для любых новых данных.

Что может пойти не так?

Алгоритм обучения

Придумав класс моделей и функцию потерь, нам остается только решить алгоритмическую задачу: как вычислить и найти *хорошую* модель из нашего класса?

Такой алгоритм будет называться **алгоритмом обучения (learning algorithm)**.

Часто алгоритм обучения будет применением какого-то известного метода оптимизации.
Но иногда это будет чем-то особенным, который только в ML встречается.

Бинарные классификаторы

Будем рассматривать бинарные классификаторы: $y \in \{-1, +1\}$.
Обучающая выборка:

$$\mathcal{D}_n = \{(x^{(1)}, y^{(1)}), \ldots, (x^{(n)}, y^{(n)})\}$$

Для любого классификатора h **ошибку обучения (training error)** определим как

$$\mathcal{E}_n(h) = \frac{1}{n} \sum_{i=1}^{n} \begin{cases} 1, & \text{если } h(x^{(i)}) \neq y^{(i)} \\ 0, & \text{иначе.} \end{cases}$$

Мы будем минимизировать $\mathcal{E}_n(h)$ и *надеяться*, что это хорошо *обобщается*, т.е. приводит к низким ошибкам на новых данных:

$$\mathcal{E}(h) = \frac{1}{n'} \sum_{i=n+1}^{n+n'} \begin{cases} 1, & \text{если } h(x^{(i)}) \neq y^{(i)} \\ 0, & \text{иначе.} \end{cases}$$

Линейные классификаторы

Далее будем рассматривать такой класс гипотез (класс моделей) — класс **линейных классификаторов** $\mathcal{H}$:

$$h(x;\theta,\theta_0) = sign(\theta^T x + \theta_0) = \begin{cases} +1 & \text{, если } \theta^T x + \theta_0 > 0 \\ -1 & \text{, иначе} \end{cases}$$

$\theta \in \mathbb{R}^d,\ \theta_0 \in \mathbb{R}$.
$x^{(i)}$ — вектор $d \times 1$
θ — вектор $d \times 1$

Линейные классификаторы: Пример

Пусть у нас h с параметрами $\theta = \begin{bmatrix} -1 \\ 1.5 \end{bmatrix}$ и $\theta_0 = 3$.

Пусть у нас есть два объекта $x^{(1)} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ и $x^{(2)} = \begin{bmatrix} 4 \\ -1 \end{bmatrix}$.

Как эти точки классифицируются согласно h?

Линейные классификаторы: Пример

Пусть у нас h с параметрами $\theta = \begin{bmatrix} -1 \\ 1.5 \end{bmatrix}$ и $\theta_0 = 3$.

Пусть у нас есть два объекта $x^{(1)} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ и $x^{(2)} = \begin{bmatrix} 4 \\ -1 \end{bmatrix}$.

Как эти точки классифицируются согласно h?

$$h(x^{(1)}; \theta, \theta_0) = sign(\begin{bmatrix} -1 & 1.5 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix} + 3) = sign(3) = +1$$

$$h(x^{(2)}; \theta, \theta_0) = sign(\begin{bmatrix} -1 & 1.5 \end{bmatrix} \begin{bmatrix} 4 \\ -1 \end{bmatrix} + 3) = sign(-2.5) = -1$$

Линейные классификаторы: Пример

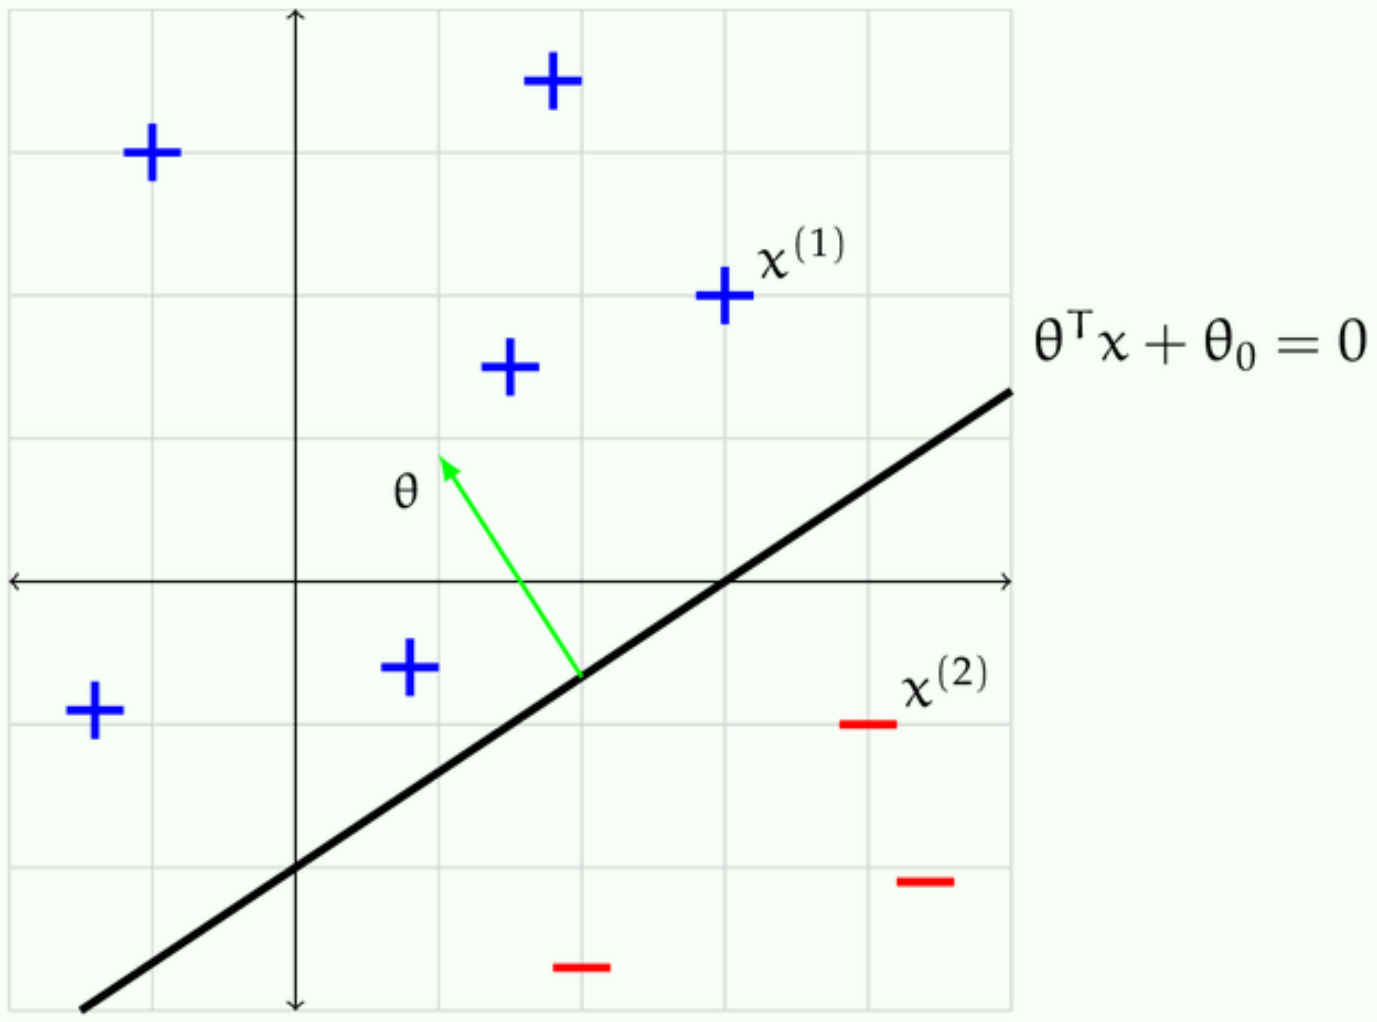

Обучение линейного классификатора

У нас есть выборка $\mathcal{D}$, конкретный класс $\mathcal{H}$ линейных классификаторов и мы минимизируем $\mathcal{E}_n(h)$.

Это уже оптимизационная задача. Остается придумать *обучающий алгоритм*.

Сейчас рассмотрим очень простой алгоритм:

$\textsc{Random-Linear-Classifier}(\mathcal{D}_n, k, d)$

1 **for** $j = 1$ **to** k

2 randomly sample $\left(\theta^{(j)}, \theta_0^{(j)}\right)$ from $(\mathbb{R}^d, \mathbb{R})$

3 $j^* = \arg\min_{j \in \{1,\ldots,k\}} \mathcal{E}_n\left(\theta^{(j)}, \theta_0^{(j)}\right)$

4 **return** $\left(\theta^{(j^*)}, \theta_0^{(j^*)}\right)$

Обучение линейного классификатора

Идея очень простая: сгенерировать k случайных модель из данного класса и выбрать из них модель с самой маленькой ошибкой на обучающей выборке.

k называется **гиперпараметром (hyperparameter)** данного обучающего алгоритма.

Как будет меняться $\mathcal{E}_n(h)$ с ростом k?